GLOBAL SOLUTION · 2º SEMESTRE

Machine Learning e Análise de Dados (MLAM) – CitizenTech

Moradia e desigualdade urbana: o que explica o valor dos imóveis nas comunidades?

Relatório estatístico

Integrante	RM
André Fujinaga	569158
Guilherme Belo	570079

Base de dados: California Housing (Censo dos EUA de 1990), 20.640 registros originais, 19.548 após a limpeza.
Ferramentas: Python (pandas, NumPy, SciPy, scikit-learn, seaborn, matplotlib), executado no Google Colab.

Resumo executivo

Pergunta: o que está associado ao valor mediano dos imóveis em comunidades urbanas?

Principais achados. (1) A **renda mediana** das famílias é o fator mais fortemente associado ao valor dos imóveis ($r = 0{,}648$; $R^2 = 42{,}05\%$ no modelo simples). (2) Com mais três variáveis (idade das construções, cômodos e pessoas por domicílio) o **R^2 ajustado sobe para 52,76%**; a ocupação do domicílio (pessoas por domicílio) tem associação negativa relevante. (3) Um classificador logístico identifica comunidades de **valor alto ou baixo com acurácia de 79,23% no teste**, contra 50,06% de uma classificação ingênua. (4) Os testes de hipótese sobre a média da renda, com amostras pequenas, não rejeitaram H_0.

Uso no CitizenTech. Os modelos permitem apontar comunidades em que o valor dos imóveis destoa do esperado pela renda e pelas condições de ocupação, apoiando diagnósticos de acessibilidade à moradia. São **associações**, não relações causais, e os dados são de 1990, restritos à Califórnia.

1. Contextualização do problema

O custo da moradia é um dos desafios centrais das cidades: define quem consegue permanecer em determinados bairros, pressiona o orçamento das famílias e orienta decisões de planejamento urbano. No desafio CitizenTech, entender o que se associa ao valor dos imóveis ajuda gestores e organizações comunitárias a priorizar territórios para políticas de habitação, infraestrutura e regularização.

Este trabalho investiga, com dados reais, como **a renda das famílias, a idade das construções e as condições de ocupação dos domicílios** (cômodos e pessoas por domicílio) se relacionam com o **valor mediano dos imóveis** das comunidades.

Objetivos específicos: (i) descrever os dados; (ii) calcular probabilidades sob a hipótese de normalidade; (iii) testar hipóteses sobre a média; (iv) quantificar a relação entre renda e valor dos imóveis; (v) construir um modelo linear múltiplo; (vi) classificar comunidades em valor alto ou baixo por regressão logística; (vii) extrair recomendações e limitações para o CitizenTech.

1.1 Justificativa da escolha da base

A base *California Housing* reúne dados reais do Censo dos EUA de 1990, agregados por comunidade (*block group*), e foi compilada por Pace e Barry (1997). Atende aos requisitos da avaliação: é real, pública, de origem conhecida, tem milhares de registros e várias variáveis quantitativas relacionadas ao tema moradia e cidades. A tentativa inicial de usar dados municipais brasileiros do IBGE foi abandonada porque a API do IBGE não respondeu de forma estável a partir do ambiente de execução; optou-se por uma base real acessível e reprodutível, sem recorrer a dados simulados.

2. Descrição dos dados e preparação

Fonte:
https://raw.githubusercontent.com/ageron/handson-ml2/master/datasets/housing/housing.csv (a mesma base está disponível em *sklearn.datasets.fetch_california_housing*). Cada linha representa uma comunidade (grupo de quarteirões). As variáveis utilizadas, já convertidas, são:

Variável	Descrição	Unidade
valor_mil	Valor mediano dos imóveis da comunidade	mil US$
renda_mil	Renda mediana anual das famílias	mil US$/ano
idade_mediana	Idade mediana das construções	anos
comodos_dom	Cômodos por domicílio (total de cômodos ÷ domicílios)	unidades
pessoas_dom	Pessoas por domicílio (população ÷ domicílios)	pessoas
populacao, latitude, longitude	População e localização da comunidade (descritivas)	–

Limpeza (reproduzível no notebook): dos 20.640 registros originais, foram removidos **992 registros com valor censurado** no teto de US$ 500.001 (o censo limita o valor máximo; esses valores não são reais e distorceriam as regressões) e **100 registros adicionais** com valores extremos implausíveis (mais de 20 cômodos ou mais de 10 pessoas por domicílio, típicos de alojamentos coletivos ou áreas não residenciais). A base final tem **19.548 comunidades**.

2.1 Estatística descritiva

Variável	Média	Desvio padrão	Mín.	25%	Mediana	75%	Máx.
valor_mil	192,22	97,17	15,00	116,58	173,90	248,10	499,10
renda_mil	36,77	15,68	5,00	25,28	34,50	45,83	150,00
idade_mediana	28,41	12,50	1,00	18,00	28,00	37,00	52,00
comodos_dom	5,27	1,37	0,85	4,41	5,18	5,96	19,96
pessoas_dom	2,94	0,77	0,75	2,45	2,84	3,30	9,95
populacao	1.443,02	1.139,59	3	800	1.182	1.749	35.682

Tabela 1 – Estatísticas descritivas (n = 19.548).

O valor dos imóveis (média 192,2; mediana 173,9) e a renda (média 36,8; mediana 34,5) têm média acima da mediana, indicando **assimetria à direita**: poucas comunidades de renda e valor muito elevados puxam a média para cima. A população apresenta valores extremos (máximo de 35.682), o que reforça cautela com a hipótese de normalidade.

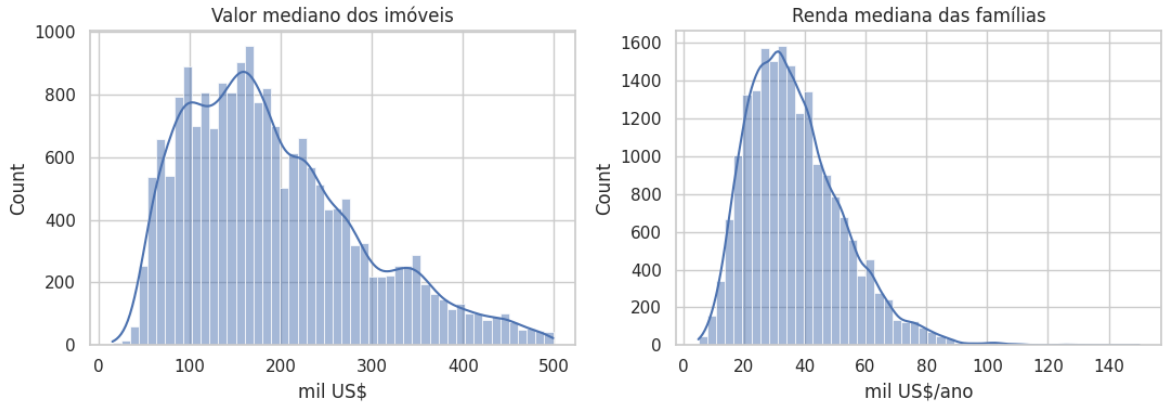


Figura 1 – Distribuição do valor mediano dos imóveis e da renda mediana (histogramas com curva de densidade).

3. Procedimentos adotados

Todas as análises foram feitas em Python com semente aleatória fixa (42) para reprodução. Os procedimentos foram:

• **Distribuição normal:** variável *renda_mil*, com $X \sim N(\mu, \sigma^2)$, usando média e desvio padrão populacional da base; cálculo de $P(X <$ média$)$ e $P(X >$ mediana$)$ e classificação do evento.

• **Testes de hipóteses:** teste Z para a média (σ conhecido = desvio padrão populacional da base), unilaterais, com amostras aleatórias: (a) H_1: $\mu < \mu_0$, $\alpha = 6\%$, $n = 20$; (b) H_1: $\mu > \mu_0$, $\alpha = 9\%$, $n = 25$. Decisão pelo valor crítico e pelo p-valor.
• **Análise bivariada:** renda (x) × valor dos imóveis (y): dispersão, covariância, correlação de Pearson, regressão linear simples, R^2, teste F e previsão com intervalo de 95%.
• **Regressão linear múltipla:** y = valor_mil; explicativas renda_mil, idade_mediana, comodos_dom e pessoas_dom. Matrizes de covariância e correlação, mínimos quadrados, testes t, R^2, R^2 ajustado, teste F, fator de inflação da variância (VIF) e análise de resíduos.
• **Regressão logística binária:** resposta alto_valor = 1 se o valor da comunidade supera a mediana da base (proporção 50%/50%); mesmas quatro explicativas; divisão treino/teste 70/30 estratificada; matriz de confusão, acurácia, sensibilidade, especificidade e precisão no treino e no teste.

4. Resultados e interpretações

4.1 Distribuição Normal de Probabilidade

Variável: renda mediana (mil US$/ano). Média μ = 36,7714; mediana = 34,5000; desvio padrão populacional σ = 15,6801.

Evento	Probabilidade	Classificação
a) P(X < média)	0,5000 (50,00%)	Evento equiprovável
b) P(X > mediana)	0,5576 (55,76%)	Evento provável (p > 0,5)

Interpretação. Em uma normal, a média divide a distribuição em duas metades iguais; logo P(X < μ) = 0,5. Já a mediana observada (34,50) é menor que a média (36,77), o que desloca P(X > mediana) para 55,76%. Essa diferença é a assinatura da **assimetria à direita** dos dados reais: a normalidade é uma aproximação útil, mas imperfeita para a renda.

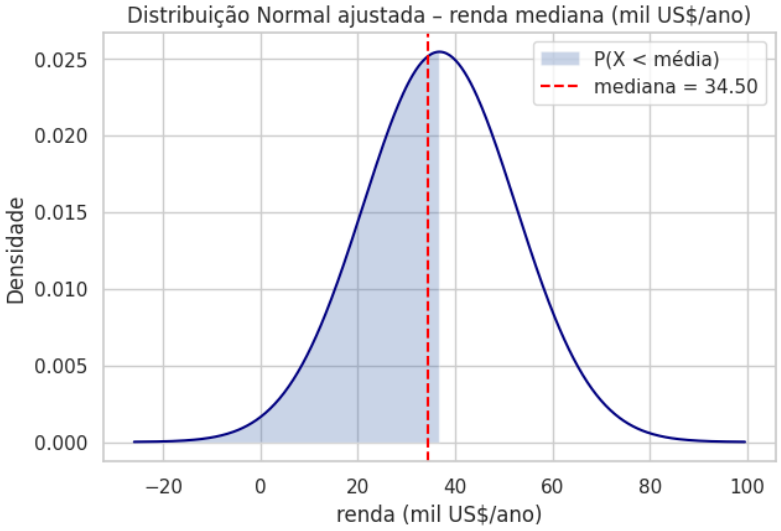


Figura 2 – Normal ajustada para a renda mediana; área sombreada = P(X < média) e linha tracejada = mediana.

4.2 Testes de hipóteses para a média (teste Z)

Hipóteses: H_0: μ = μ_0 = 36,7714 (média de referência) e σ = 15,6801.

Teste	H_1	α	n	Média amostral	Z calculado	Z crítico	p-valor	Decisão
a	$\mu < \mu_0$	6%	20	39,7722	0,8559	−1,5548	0,8040	Não rejeita H_0
b	$\mu > \mu_0$	9%	25	36,7159	−0,0177	1,3408	0,5071	Não rejeita H_0

Interpretação. No teste (a), a média amostral (39,77) ficou *acima* de μ_0, o oposto do que H_1 afirma; Z = 0,86 está longe da região crítica (Z < −1,55) e o p-valor (0,804) é muito maior que 6%. No teste (b), a média amostral (36,72) praticamente coincide com μ_0 (Z ≈ −0,02), e o p-valor (0,507) supera 9%. Em ambos, **não há evidência para rejeitar H_0**. Isso não prova que as médias são iguais; apenas indica que essas amostras pequenas, retiradas de uma população cuja média é, por construção, μ_0, não mostram diferença significativa. Com outra semente aleatória a decisão poderia variar, o que é esperado pelo erro amostral.

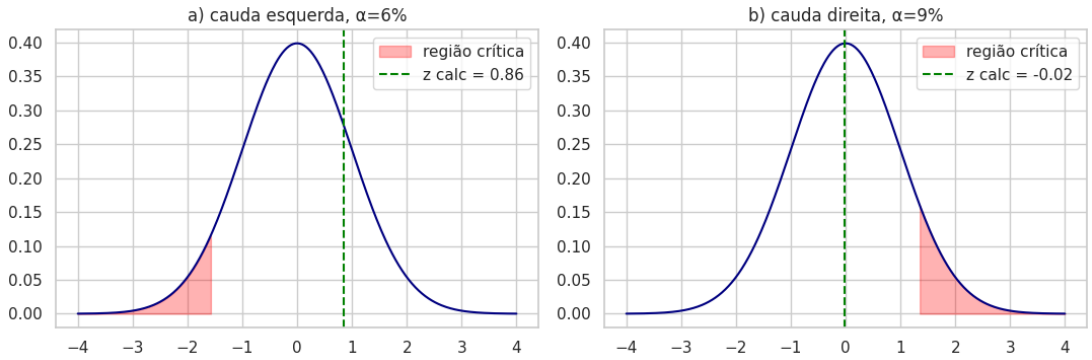


Figura 3 – Regiões críticas e Z calculado dos testes (a) e (b).

4.3 Análise bivariada e regressão linear simples

Variáveis: renda mediana (x) e valor mediano dos imóveis (y).

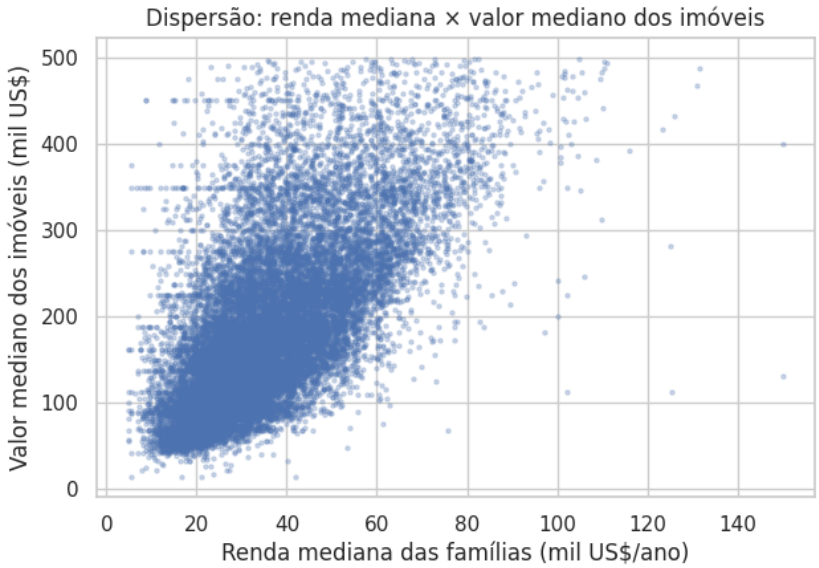


Figura 4 – Dispersão: renda mediana × valor mediano dos imóveis.

(a) Dispersão. A nuvem de pontos mostra tendência **crescente**: comunidades de maior renda tendem a ter imóveis mais valorizados. A dispersão em torno da tendência é grande e aumenta com a renda (maior variabilidade do valor entre comunidades de renda alta). Observam-se faixas horizontais de pontos, decorrentes de valores repetidos na base, e poucos pontos de renda muito alta (> 100 mil US$/ano).

Medida	Valor	Leitura
Covariância amostral	987,9382	Positiva: renda e valor variam no mesmo sentido (depende das unidades)
Correlação de Pearson (r)	0,6484	Linear **moderada e positiva**; p < 0,001
R^2	0,4205	42,05% da variação do valor é explicada pela renda
Teste F (H_0: $\beta_1 = 0$)	14.180,43	p < 0,001: modelo significativo

(b) Covariância e correlação. A covariância positiva (987,94) confirma o sentido da relação, e r = 0,648 mostra associação moderada a forte; correlação, porém, **não implica causalidade**.

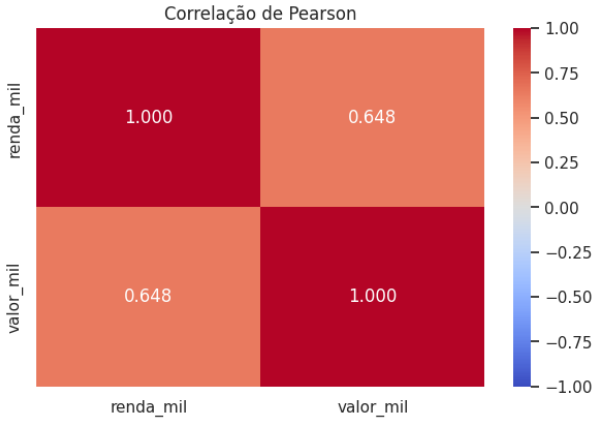


Figura 5 – Mapa de calor da correlação de Pearson (renda × valor).

(d) Reta de regressão.

$$\text{valor_mil} = 44{,}4756 + 4{,}0180 \cdot \text{renda_mil}$$

Interpretação. Cada aumento de 1 mil US$/ano na renda mediana está associado, em média, a um aumento de **4,02 mil US$** no valor mediano dos imóveis. O intercepto (44,48) é o valor esperado para renda nula e serve apenas de ajuste da reta, pois não há comunidades com renda próxima de zero (mínimo 5,0).

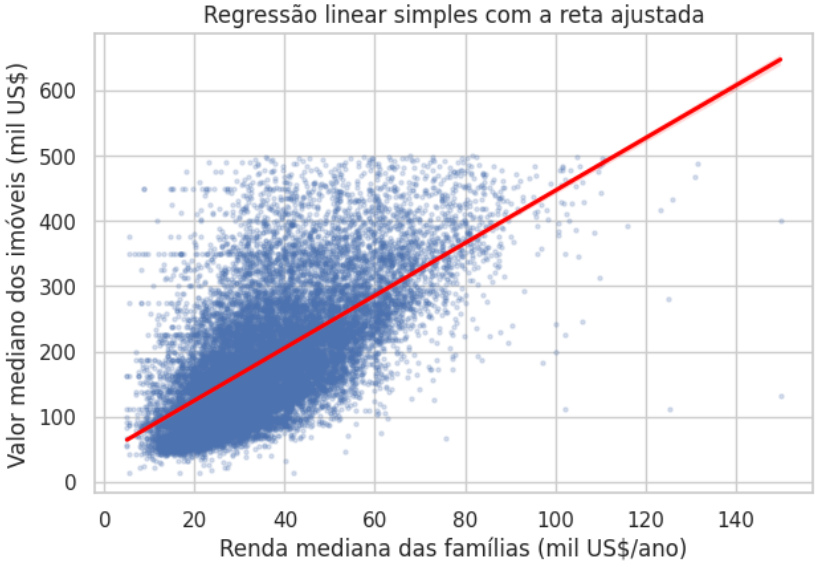


Figura 6 – Reta de regressão linear simples sobre o gráfico de dispersão.

(e) Adequação do modelo. O teste F rejeita H_0 ($\beta_1 = 0$) com folga, portanto a renda tem relação linear significativa com o valor. O $R^2 = 0{,}4205$ indica poder explicativo moderado: **mais da metade da variação (57,95%) depende de outros fatores**, como localização, características das construções e da vizinhança. Com 19.548 observações, a significância estatística é quase inevitável; o R^2 é a medida mais informativa sobre a utilidade prática.

(f) Previsão. Para uma comunidade com renda mediana de 50 mil US$/ano, o modelo prevê valor de **≈ 245,4 mil US$**, com intervalo de previsão de 95% de 100,4 a 390,4 mil US$. A amplitude do intervalo (≈ 290 mil US$) mostra que a previsão para uma comunidade individual é pouco precisa, embora a tendência média seja bem estimada.

4.4 Regressão linear múltipla

Variável resposta: valor_mil. Explicativas: renda_mil, idade_mediana, comodos_dom e pessoas_dom.

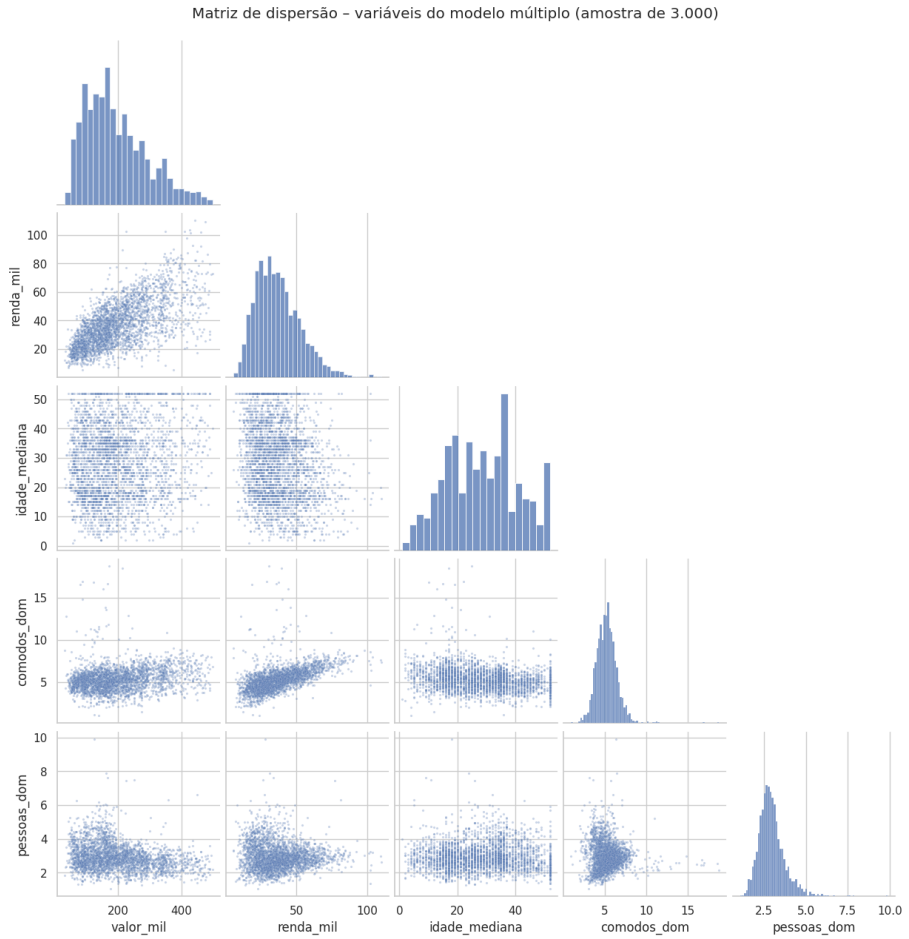


Figura 7 – Matriz de dispersão das variáveis do modelo (amostra de 3.000 comunidades).

(a) Dispersão. A renda mostra relação crescente e nítida com o valor. Pessoas por domicílio tem relação levemente decrescente, e idade mediana e cômodos por domicílio têm relações fracas com o valor. Entre as explicativas, destaca-se a relação positiva entre renda e cômodos por domicílio.

(b–c) Covariância e correlação. Matriz de correlação de Pearson:

	valor_mil	renda_mil	idade_mediana	comodos_dom	pessoas_dom
valor_mil	1,0000	0,6484	0,0647	0,2037	−0,2428
renda_mil	0,6484	1,0000	−0,1967	0,5505	−0,0533
idade_mediana	0,0647	−0,1967	1,0000	−0,2519	0,0140
comodos_dom	0,2037	0,5505	−0,2519	1,0000	−0,0554
pessoas_dom	−0,2428	−0,0533	0,0140	−0,0554	1,0000

Tabela 2 – Correlação de Pearson. A matriz de covariância completa está no notebook (valor_mil: variância 9.441,06; renda_mil: 245,88; covariância valor × renda: 987,94).

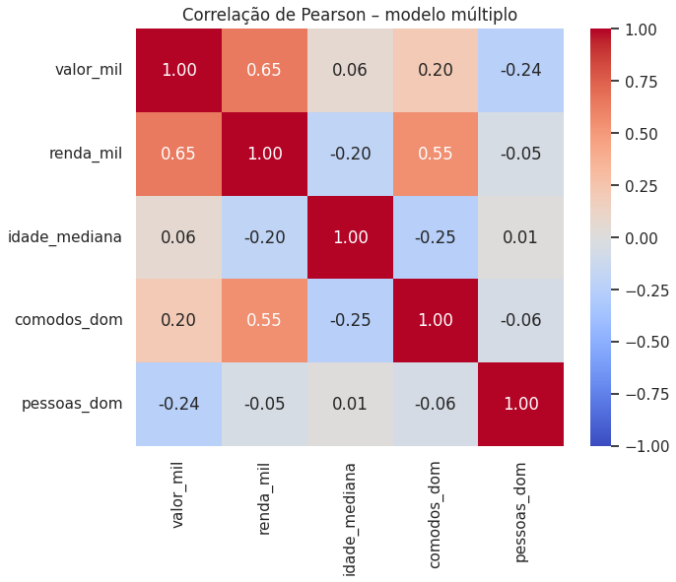


Figura 8 – Mapa de calor da correlação de Pearson (modelo múltiplo).

Interpretação. A renda tem a maior correlação com o valor (0,648). As demais são fracas (idade 0,065; cômodos 0,204; pessoas −0,243). A correlação mais alta *entre explicativas* é renda × cômodos (0,551), moderada, o que não inviabiliza o modelo (ver VIF).

(d) Equação estimada.

valor_mil = 129,0718 + 4,8133·renda_mil + 1,3376·idade_mediana − 13,6228·comodos_dom − 27,2077·pessoas_dom

Termo	Coeficiente	Erro padrão	t	p-valor	VIF
Constante	129,0718	3,1625	40,81	< 0,001	–
renda_mil	4,8133	0,0366	131,52	< 0,001	1,44
idade_mediana	1,3376	0,0396	33,77	< 0,001	1,07
comodos_dom	−13,6228	0,4236	−32,16	< 0,001	1,48
pessoas_dom	−27,2077	0,6247	−43,55	< 0,001	1,00

Tabela 3 – Coeficientes da regressão linear múltipla (n = 19.548).

Interpretação dos coeficientes (mantidas as demais variáveis constantes): +1 mil US$/ano de renda associa-se a +4,81 mil US$ no valor; +1 ano de idade mediana das construções, a +1,34 mil US$; +1 cômodo por domicílio, a −13,62 mil US$; e +1 pessoa por domicílio, a **−27,21 mil US$**. O sinal negativo de cômodos por domicílio contrasta com sua correlação simples positiva (0,204): como cômodos e renda são correlacionados (0,551), a associação positiva simples é em grande parte um reflexo da renda; ao controlar a renda, comunidades com mais cômodos por domicílio não têm valor maior. Já o efeito negativo das pessoas por domicílio é consistente com adensamento domiciliar mais elevado em áreas de menor valor. São associações condicionais, não efeitos causais.

(e) Adequação. R^2 = 0,5277 e R^2 ajustado = 0,5276: as quatro variáveis explicam **52,76%** da variação do valor dos imóveis, ganho de cerca de 10,7 pontos percentuais sobre o modelo só com renda (42,05%). O teste F global (F = 5.458,80; gl = 4 e 19.543; p < 0,001) rejeita a hipótese de que todos os coeficientes são nulos, e todos os testes t são significativos. Os VIF (de 1,00 a 1,48) são muito inferiores a 5, sem multicolinearidade preocupante. Ainda restam cerca de 47% da variação não explicada.

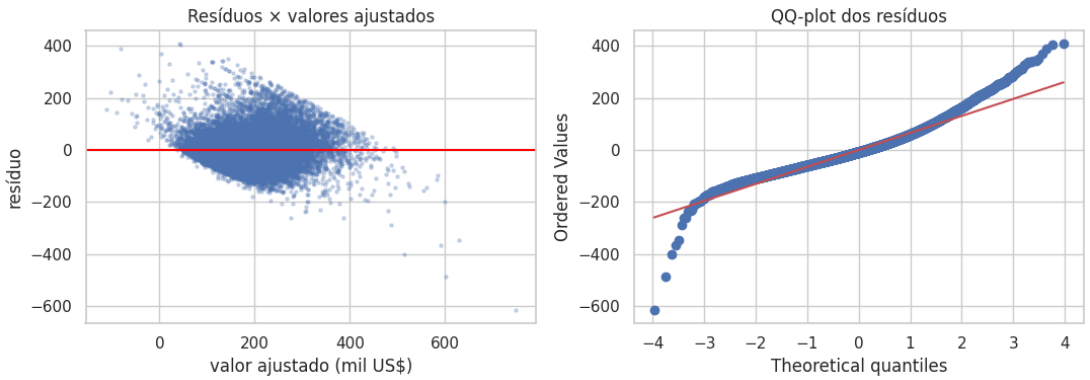


Figura 9 – Resíduos × valores ajustados e QQ-plot dos resíduos.

Diagnóstico dos resíduos. O gráfico revela: (i) variabilidade dos resíduos que cresce com o valor ajustado (heterocedasticidade); (ii) uma borda superior inclinada, efeito de os valores terem sido truncados em 500 mil US$ (registros censurados removidos); (iii) caudas pesadas no QQ-plot, ou seja, os resíduos não são normais, sobretudo nos extremos; e (iv) alguns valores ajustados negativos, absurdos para um preço. Assim, o modelo é útil para descrever tendências, mas os p-valores e intervalos devem ser lidos com cautela e as previsões, especialmente nos extremos, são aproximadas.

(f) Previsão. Para uma comunidade com renda de 40 mil US$/ano, idade mediana de 30 anos, 5 cômodos e 3 pessoas por domicílio, o modelo prevê valor mediano de **≈ 212,0 mil US$**.

4.5 Regressão logística binária

Variável resposta: alto_valor = 1 se o valor da comunidade supera a mediana da base (173,9 mil US$). As classes ficam equilibradas (50,06% e 49,94%). Treino: 13.683 comunidades; teste: 5.865.

(a) Equação do modelo.

$$\text{logit}(p) = \ln[p/(1-p)] = -0{,}6183 + 0{,}1575\cdot\text{renda_mil} + 0{,}0340\cdot\text{idade_mediana} - 0{,}6552\cdot\text{comodos_dom} - 0{,}8892\cdot\text{pessoas_dom}$$

onde $p = 1 / (1 + e^{-\text{logit}})$ é a probabilidade de a comunidade ter valor acima da mediana.

Variável	Coeficiente	Razão de chances (e^β)	Leitura
renda_mil	0,1575	1,1706	+1 mil US$/ano multiplica as chances por 1,17 (+17%)
idade_mediana	0,0340	1,0346	+1 ano: chances +3,5%
comodos_dom	−0,6552	0,5194	+1 cômodo/dom: chances −48% (a renda constante)
pessoas_dom	−0,8892	0,4110	+1 pessoa/dom: chances −59%

Tabela 4 – Coeficientes e razões de chances (efeitos com as demais variáveis constantes).

(b) Matriz de confusão e acurácia.

Conjunto de TESTE	Previsto: valor baixo	Previsto: valor alto
Real: valor baixo	2.349 (verdadeiros negativos)	587 (falsos positivos)
Real: valor alto	631 (falsos negativos)	2.298 (verdadeiros positivos)

Conjunto	Acurácia	Sensibilidade	Especificidade	Precisão
Treino	80,11%	79,58%	80,63%	80,38%
Teste	79,23%	78,46%	80,01%	79,65%
Referência (classe majoritária)	50,06%	–	–	–

Tabela 5 – Matriz de confusão (teste) e métricas de desempenho.

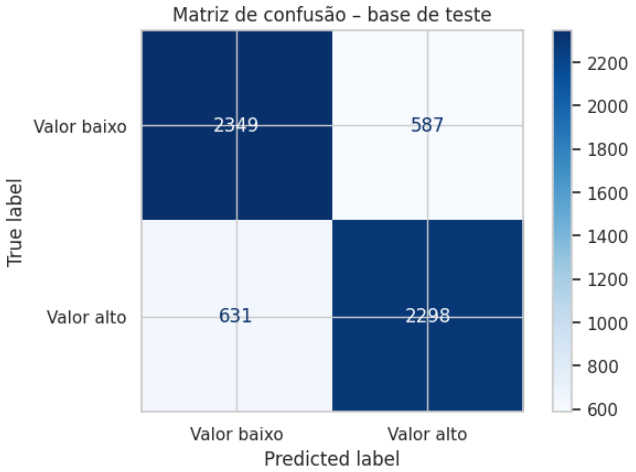


Figura 10 – Matriz de confusão na base de teste.

Interpretação. O modelo acerta **79,23%** das classificações no teste (1.218 erros em 5.865), quase 29 pontos percentuais acima da linha de base de 50,06%. Os erros são equilibrados: sensibilidade de 78,46% (acerta 4 em cada 5 comunidades de valor alto) e especificidade de 80,01% (acerta 4 em cada 5 de valor baixo). A diferença entre treino (80,11%) e teste (79,23%) é de apenas 0,88 ponto percentual, sem sinal de sobreajuste. Os erros concentram-se, naturalmente, em comunidades próximas da mediana, onde a fronteira entre as classes é tênue.

(c) Classificação. Para uma comunidade com renda de 60 mil US$/ano, idade mediana de 25 anos, 6 cômodos e 2,5 pessoas por domicílio, a probabilidade de valor acima da mediana é **97,14%**, e ela é classificada como **valor ALTO**.

5. Conclusões e aplicação no CitizenTech

1. A renda é o principal fator associado ao valor dos imóveis. A correlação de 0,648 e o R^2 de 42,05% do modelo simples mostram relação forte e positiva, mas incompleta.

2. As condições de ocupação importam além da renda. No modelo múltiplo (R^2 ajustado = 52,76%), mais pessoas por domicílio estão associadas a valores menores (−27,2 mil US$ por pessoa adicional, renda constante). Esse indicador pode funcionar como *sinal de alerta* de adensamento domiciliar em comunidades de menor valor.

3. É possível classificar comunidades com boa acurácia. O modelo logístico separa comunidades de valor alto e baixo com 79,23% de acerto no teste, usando apenas quatro variáveis de censo.

Como usar no CitizenTech:

• *Triagem territorial:* comparar o valor observado com o esperado pelo modelo (resíduo) para localizar comunidades cujos imóveis são muito mais caros (risco de pressão por valorização e exclusão) ou muito mais baratos do que a renda sugere, para investigação com dados locais.
• *Monitoramento:* acompanhar renda, ocupação dos domicílios e valor dos imóveis ao longo do tempo para antecipar áreas de vulnerabilidade habitacional.
• *Comunicação com a comunidade:* os coeficientes traduzem em números simples (por exemplo,

quanto o valor varia a cada 1 mil US$ de renda), úteis para diagnósticos participativos.
Os resultados orientam onde olhar, mas **não substituem estudos locais** nem permitem afirmar causalidade.

6. Limitações

• **Dados antigos e de outro país:** Censo de 1990 da Califórnia; os padrões não se transferem automaticamente ao Brasil nem ao presente.
• **Unidade de análise agregada:** os dados são de comunidades, não de famílias; relações observadas no agregado podem não valer para indivíduos (falácia ecológica).
• **Censura do valor:** imóveis acima de US$ 500 mil foram removidos (992 registros), o que subestima o topo da distribuição e produz o truncamento visível nos resíduos.
• **Pressupostos dos modelos:** os resíduos apresentam heterocedasticidade e caudas pesadas; a renda é assimétrica, logo a normalidade é apenas aproximada; podem ocorrer previsões negativas nos extremos.
• **Poder explicativo parcial:** 47% da variação do valor permanece sem explicação (localização, qualidade da construção, infraestrutura, acesso a serviços etc.). Latitude e longitude não foram usadas como explicativas.
• **Testes de hipótese:** usam amostras pequenas (n = 20 e 25) e tomam a média da base como referência populacional; o resultado depende da amostra sorteada.
• **Significância e relevância:** com quase 20 mil observações, praticamente todo efeito é estatisticamente significativo; a relevância prática deve ser julgada pela magnitude dos coeficientes e pelo R^2.
• **Associação não é causalidade:** nenhuma conclusão deste relatório implica que alterar uma variável cause mudança no valor dos imóveis.

7. Reprodutibilidade

O notebook *GS_MLAM_2SEM_1.ipynb* contém todo o código, com as saídas preservadas, e reproduz a coleta, a limpeza e todas as análises (semente 42). A base limpa utilizada está em *base_california_housing_limpa.csv*. As instruções de execução constam no README.md do repositório.

Referências

PACE, R. K.; BARRY, R. Sparse spatial autoregressions. *Statistics & Probability Letters*, v. 33, n. 3, p. 291–297, 1997.
GÉRON, A. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*. 2. ed. O'Reilly, 2019. Base disponível em github.com/ageron/handson-ml2.
PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *JMLR*, v. 12, p. 2825–2830, 2011.